

# RELATÓRIO FINAL ITAÚ ASSET QUANTAMENTAL 2023

---

## AABA - ALPHA QUANT

## Explicação do Nome:

O Alpha Quant leva esse nome, pois visa obter um Alpha em relação a média de retorno no mercado de ações, isso é feito de forma totalmente sistemática, sem interferência de tomada de decisão humana, apenas utilizando um modelo de fatores.

## Design do Alpha Quant:



## Racional Estratégia e Demais informações:

Nossa estratégia consiste em sistematizar e otimizar para o mercado brasileiro a Magic Formula desenvolvida pelo gesto de Hedge Funds e investidor Joel Greenblatt.

Utilizando os fatores de EV/EBIT e ROIC, o modelo vai criar um ranking mensal com as 10 mais bem colocadas empresas no Brasil.

Nossa estratégia é do tipo Portfólio, para o universo de Ações em todo o mercado brasileiro, sem limitação de volume de negociação, setor ou valor de mercado. Trabalhamos com uma Média de 3 trades por mês e um Holding Period de 2 meses aproximadamente, para a realização do backtest utilizamos o Python, majoritariamente com a biblioteca Pandas.

O benchmark para nosso modelo quantitativo é o Ibovespa, visto que o Alpha Quant opera no universo de Ações Brasileiras.

## Apresentando a Estratégia

A Magic Formula é uma estratégia de investimentos elaborada pelo investidor Joel Greenblatt e apresentada detalhadamente no livro “The Little Book That Beats the Market”. Após ler esse livro, percebemos como uma estratégia simples poderia gerar um retorno superior quando se comparado a média do mercado.

A simplicidade da estratégia e o grande sucesso no mercado americano, nos fez perceber como essa forma simples e com base em fatores bem definido podia também funcionar no mercado brasileiro.



Figura 1 – Backtest da Magic Formula no mercado Americano

Assim que compreendemos o quão simples é a Magic Formula e como ela realmente pode trazer bons resultados no longo prazo e bater o mercado, só nos restava compreender qual era a mecânica do modelo e aplicar isso com os dados do Brasil.

O cerne da estratégia baseia-se em criar um ranking mensal com as melhores ações de acordo com os seguintes critérios:

### 1) Desconto sobre o preço de mercado para empresas com operação rentável

Mesmo que o mercado seja eficiente na maior parte do tempo, divergências de Preço x Valor existem, e a Magic Formula adota como um fator positivo ações que estejam em um nível atrativo, para isso utilizamos o índice EBIT/EV, assim vamos conseguir colocar em uma classificação as empresas com a maior geração de caixa operacional (EBIT) em relação ao seu valor de firma.

Para isso utilizamos os dados de EV/EBIT e invertemos para obter o EBIT/EV, de forma que quanto maior o indicador, melhor a posição em nosso ranking.

## 2) Rentabilidade sobre o capital

Podemos definir o ROIC como sendo o indicador de qualidade de nossa fórmula, enquanto o EBIT/EV seria o indicador de preço, o ROIC é calculado pelo lucro operacional (EBIT) dividido pelo valor total dos ativos fixos (Property, Plant and Equipment) e o NWC (Net Working Capital).

Essa forma de definir os ativos é utilizada a partir das regras do próprio livro, buscando assim isolar apenas os ativos que produzem lucros operacionais, ao invés da clássica soma de Dívida + Equity.

Existem algumas outras considerações que o livro propõe, porém não as consideramos para efeito de otimização no mercado brasileiro.

Primeiramente Greenblatt sugere que não sejam incluídos os setores Financeiro e de Utilities, além de definir um capital mínimo e volume de negociação, tendo em vista a limitação em questão de quantidade de empresas, decidimos manter essas regras fora do modelo.

Entre julho de 2003 e dezembro de 2015, a Magic Formula retornou anualmente 11.4% com um índice Sharp de 0.6, contra 8.7% ao ano do S&P500 e um índice Sharpe de 0.54. Isso nos mostra duas coisas, primeiro que a fórmula teve um alpha de 3% contra o benchmark, porém abaixo do que o primeiro portfólio feito por Greenblatt, isso acontece devido a criação de ETFs que replicam estratégias quantitativas como essa, corrigindo a ineficiência do mercado e diminuindo as diferenças de Preço x Valor que geram os lucros expressivos no mercado de Ações.

Tendo todos esses pontos em vista, desde a teoria de como a escolha de empresas rentáveis e baratas, pode trazer um retorno acima da média com ações até a própria mecânica de como devemos calcular o ranking com base em rentabilidade e preços baixos.

Por fim ficou claro que nosso universo deveria ser o Brasil, um mercado mais recente, mais limitado e mesmo com uma distribuição de empresas e setores totalmente diferente do S&P, poderíamos obter um retorno sobre a ineficiência local selecionando as melhores empresas sistematicamente.

Comparação Setorial: S&P 500 vs. Ibovespa			
Principais Setores do Ibovespa		Principais Setores do S&P 500	
Óleo e Gás	19,3%	Energia	12,4%
Materiais Básicos	31,0%	Materiais Básicos	3,2%
Financeiro	22,0%	Financeiro	13,6%
Construção e Transportes	6,0%	Industrial	9,9%
Consumo não cíclico	6,3%	Bens de Luxo	9,0%
Consumo cíclico	3,2%	Bens de Necessidade	12,0%
Tecnologia	0,0%	Tecnologia	18,3%
Telecomunicações	4,3%	Telecomunicações	3,5%
Utilidades	7,2%	Utilidades	4,1%
Bens de produção	0,7%	Saúde	14,0%
<b>Total</b>	<b>100%</b>	<b>Total</b>	<b>100%</b>

Fonte: Standard & Poor's

Figura 2 – Comparação Setorial IBOV vs S&P

S&P500	Part %	IBOVESPA	Part %
Microsoft	4,3%	Itau/Itausa	12,8%
Apple	4,3%	Petrobras ON+PN	12,3%
Amazon	2,9%	Vale	8,4%
Facebook	1,8%	Bradesco ON+PN	9,3%
JPMorgan	1,6%	B3	5,3%
5 Grupos	14,9%	5 Grupos	48,1%

Figura 3 – Concentração das maiores posições do IBOV vs S&P

### Implementação da Estratégia

Agora que já temos o racional da estratégia, vamos para a implementação, a primeira etapa será coletar os dados necessários e chegar em uma tabela final com tudo consolidado, os dados a serem coletados são os seguintes:

**DATA**

**TICKER**

**PREÇO DE FECHAMENTO**

**EBIT/EV**

**IBOV**

A tabela que vamos chegar ao final de todo esse processo de coleta e tratamento de dados deve ser a seguinte, com todas as informações acima mensalmente no último dia do mês, que é como vamos calcular os rankings de forma mensal e rodar a carteira, mantendo as vencedoras e retirando as perdedoras com base na classificação, mantendo sempre o padrão de 10% de peso para cada posição.

	TICKER	DATA	VOLUME	FECHAMENTO_AJUSTADO	ROIC	VALOR_MERCADO	EBIT_EV
0	AALR3	2016-12-31	5375545.0	14.45	0.05890	7.313816e+08	0.08785
1	AALR3	2017-01-31	3116406.0	13.75	0.05890	7.004290e+08	0.09011

Figura 4 – Exemplo de tabela completa

Agora que já sabemos quais dados precisamos coletar, fomos a prática, utilizamos a API FINTZ, nela conseguimos coletar os dados de preços e indicadores diariamente, no caminhar dessa jornada, enfrentamos alguns desafios de tratamento de dados, que vamos entender melhor a partir de agora.

O primeiro desafio era manter somente as datas de último dia do mês para todos os indicadores, tínhamos um arquivo por indicador e um para as cotas, que recebemos como retorno da API, assim desenvolvemos um código em Python para realizar esse filtro (filtra\_data.py).



Feito esse filtro, agora tínhamos um novo desafio, juntar todos esses dados, para isso criamos uma função em Python (junta\_dados.py) e através do merge, conseguimos juntar todos os indicadores e os preços em uma só base de dados.

Agora com todos os dados conectados e com somente o último dia de cada mês, estávamos com tudo pronto para iniciar definitivamente a implementação do modelo, porém durante uma validação de dados, verificamos que diversas empresas tinham buracos de preços na base de dados e para fins de simplificação, resolvemos retirar essas empresas da base pois esses buracos de informação distorciam toda a análise, e para isso utilizamos a nossa função (filtra\_vazios.py).

Uma última transformação que fizemos foi ajustar o indicador EV/EBIT para EBIT/EV, fazendo  $1/(EV/EBIT)$  para que assim possamos analisar de forma padronizada esse indicador junto com o ROIC, de forma que quanto maior, mais alta a posição no Ranking.

Finalmente com a base de dados completa e tratada, podíamos implementar a Magic Formula no mercado brasileiro, sendo assim, dentro de nosso código em Python (Main.py) executamos as seguintes etapas:

1. Inserir as bibliotecas e dados
2. Calcular o retorno mensal por empresa mês a mês
3. Criar um ranking considerando o ROIC o EBIT/EV

```
1 dados_empresas[dados_empresas['DATA'] == '2019-12-31'].sort_values('RANKING_FINAL').head(10)
```

	TICKER	DATA	VOLUME	FECHAMENTO_AJUSTADO	ROIC	VALOR_MERCADO	EBIT_EV	RETORNO	RANKING_EV_EBIT	RANKING_ROIC	RANKING_FINAL
1546	ATOM3	2019-12-31	67222.0	1.24	1.11522	3.489966e+07	0.19125	0.064516	8.0	5.0	1.0
15962	MNDL3	2019-12-31	3513.0	35.13	1.09290	8.713153e+07	0.16784	-0.032166	9.0	6.0	2.0
5914	CRPG5	2019-12-31	714335.0	17.86	0.22134	7.570176e+08	0.23156	0.019037	3.0	15.0	3.0
4195	CGAS3	2019-12-31	53300.0	112.96	0.24499	1.892251e+10	0.12767	0.387217	18.5	13.5	4.5
4340	CGAS5	2019-12-31	1125415.0	110.16	0.24499	1.892251e+10	0.12767	0.404684	18.5	13.5	4.5
11233	GOLL4	2019-12-31	96809854.0	36.80	2.74871	1.288405e+10	0.11138	-0.069293	32.0	2.0	6.0
2959	BRAP3	2019-12-31	88419.0	21.24	0.18841	1.296722e+10	0.15191	-0.010829	13.5	21.5	7.5
3103	BRAP4	2019-12-31	60255324.0	22.85	0.18841	1.296722e+10	0.15191	-0.033260	13.5	21.5	7.5
8102	ELET6	2019-12-31	80411930.0	31.25	0.13568	5.124643e+10	0.20827	0.068800	5.5	49.5	9.5
7958	ELET3	2019-12-31	84329045.0	32.86	0.13568	5.124643e+10	0.20827	0.037432	5.5	49.5	9.5

Figura 5 – Ranking Modelo

4. Criar as carteiras mensais com as 10 melhores ações de acordo com o modelo

```
1 carteira_top_10[carteira_top_10['DATA'] == '2011-10-31']
```

	TICKER	DATA	VOLUME	FECHAMENTO_AJUSTADO	ROIC	VALOR_MERCADO	EBIT_EV	RETORNO	RANKING_EV_EBIT	RANKING_ROIC	RANKING_FINAL
1932	BAHI3	2011-10-31	873.0	10.01	0.82267	5.234800e+07	-88.73114	-0.072927	19.0	1.0	9.5
2077	BAUH4	2011-10-31	4800.0	2.35	0.28277	1.514444e+07	0.24170	0.004255	2.0	2.0	1.0
4097	CGAS3	2011-10-31	596883.0	10.13	0.16184	3.900412e+09	0.11406	0.012833	8.5	8.5	6.0
4242	CGAS5	2011-10-31	1963503.0	10.00	0.16184	3.900412e+09	0.11406	0.029000	8.5	8.5	6.0
5164	COCE5	2011-10-31	1179556.0	21.79	0.23278	2.494581e+09	0.18901	-0.056448	4.0	4.0	4.0
6152	CSNA3	2011-10-31	58392287.0	8.58	0.14658	2.391071e+10	0.15885	-0.072261	5.0	12.0	6.0
9046	EQTL3	2011-10-31	1198442.0	1.81	0.18883	1.228800e+09	0.24733	0.033149	1.0	5.0	2.5
14646	LREN3	2011-10-31	62454582.0	6.25	0.16535	6.470693e+09	0.06461	0.040000	13.0	7.0	9.5
18615	PLAS3	2011-10-31	549824.0	118.32	0.13182	3.827890e+08	0.14332	-0.146467	6.0	13.0	8.0
26234	VALE3	2011-10-31	164390535.0	23.20	0.23689	2.330000e+11	0.20600	-0.046983	3.0	3.0	2.5

Figura 6 – Exemplo de carteira

5. Calcular a rentabilidade mensal das carteiras
6. Calcular a rentabilidade acumulada do modelo




Figura 7 – Multiplicação do Patrimônio Investido pelo Modelo

7. Coletar dados do IBOVESPA e calcular sua rentabilidade no mesmo período




Figura 8 – Multiplicação do Patrimônio Modelo x Ibovespa

## 8. Analisar os Resultados

Primeiramente calculamos a rentabilidade anual do nosso modelo, considerando que a última carteira fechada foi a de 18/10/2023:

```
1 rentabilidade_ano = (1 + rentabilidade_carteira.loc['2023-10-18', 'RETORNO_MODELO']) ** (1/11.98) - 1
2
3 rentabilidade_ano
0.30565130619868097
```

Figura 9 – Cálculo da Rentabilidade Anualizada

Com isso podemos verificar que o modelo da Magic Formula aplicado ao mercado brasileiro teve um retorno de 30% ao ano em média, superando assim o benchmark IBOV.

Além disso realizamos algumas visualizações em formato de Heat Map, para podemos analisar a rentabilidade em percentual acumulada desde o início da carteira contra o benchmark.

Carteira:




Figura 10 – Rentabilidade (%) acumulada do Modelo



Benchmark:




Figura 11 – Rentabilidade (%) acumulada do Benchmark

## Conclusão

Com a conclusão do backtest e a análise dos resultados, verificamos que a Magic Formula realmente pode gerar um Alpha no mercado brasileiro, assim como fez no mercado americano. Percebemos que um modelo totalmente sistemático é capaz de escolher boas empresas mesmo em períodos de maior volatilidade, aonde a tomada de decisão humana é comprometida devido a fatores emocionais e aversão natural ao risco.

Também conseguimos analisar que a Magic Formula possui um risco maior que o benchmark, principalmente em períodos de maior recessão aonde as empresas justamente se encontram em um período mais favorável para boas compras, porém o mercado acaba ficando mais cauteloso, justamente por essa tomada maior de risco o modelo consegue entregar um retorno bem superior a média.

Em relação ao processo de decisão de qual seria a ideia escolhida, no começo estávamos muito dispersos para escolher uma estratégia com fundamentos lógicos, que seja efetivamente lucrativa e principalmente, factível de realizar um backtest com os dados e conhecimentos que tínhamos, como muitos no grupo achavam interessante o mercado de ações, escolhemos a estratégia por trás do livro e iniciamos a pesquisa teórica de como funcionaria e de como poderíamos implementar.

Dentre todos os desafios do projeto, as etapas de coleta, limpeza e organização dos dados foi certamente a mais trabalhosa para o time, como os dados de preços que tínhamos disponíveis eram diários, e nossas carteiras eram mensais, precisamos primeiramente realizar esse filtro de somente dados mensais para todos os indicadores e preços, além de depois juntar tudo em uma base de dados unificada, esta que seria utilizada pra rodar efetivamente o modelo.

Por fim a organização do backtest também foi um novo desafio para todos no grupo, principalmente em relação aos cálculos de rentabilidade e a utilização de funções para organização e tratamento de dataframes.

Para garantir a robustez do modelo e dos dados, realizamos checks em Python para tratamentos de buracos de preços, rentabilidades explodidas e qualquer indicativo de dado incorreto em nossa base, igualmente para as fontes de dados, buscamos utilizar os dados em somente duas bases que consideramos confiáveis, primeiramente a API da Fintz, e para o IBOV utilizamos a biblioteca Yahoo Finance direto no código do modelo.

Em resumo o desafio foi muito proveitoso para todos no grupo, sendo os principais pontos a compreensão do que é um modelo quantitativo e como a mecânica funciona na prática, como coletar dados e limpá-los para serem utilizados no modelo, como trabalhar em equipe para conseguir entregar um trabalho robusto e de acordo com o que a estratégia se propõe.

Todos os códigos utilizados no desafio estão disponíveis dentro de um repositório Git e podem ser disponibilizados assim que solicitados pela equipe avaliadora, eles não foram inseridos nesse relatório para preservar o anonimato proposto para fins de avaliação.

Existem também alguns pontos de melhoria para o projeto, entre eles estão a Automatização da Coleta e Limpeza dos Dados, Geração de Dashboards e Análises Gráficas em nuvem para análise em tempo real, Rentabilidade diária das carteiras entre outras melhorias no mecanismo de implementação da estratégia e visualização dos resultados.

Já para a estratégia em si, existem pontos de melhoria que podem otimizar a Magic Formula e consequentemente gerar um Alpha ainda maior. Sendo os fatores:

**Fatores Compostos:** Uma abordagem de otimização envolve a agregação de métricas diversas em vez de depender de um único indicador para avaliar a atratividade das ações. Pode-se desenvolver um fator composto que combina várias métricas relacionadas à avaliação das ações. Além de fatores de riscos e de dados alternativos, que ampliam a estratégia como um todo, monitorando também o risco da carteira.

**Estratégia Long/Short (Compra/Venda):** A estratégia pode ser aprimorada consideravelmente ao adotar uma abordagem de portfólio long/short em vez de se restringir a compras. Nesse cenário, a estratégia identifica tanto ativos com forte desempenho quanto ativos com desempenho fraco e, assim, cria uma estratégia de cobertura para se proteger contra movimentos amplos de mercado.